

《机器学习》课程系列

雅可比矩阵*

Jacobian Matrix

武汉纺织大学数学与计算机学院

杜小勤

2020/07/11

Contents

1	定积分的换元法	1
2	极坐标换元法	2
3	雅可比矩阵	4
4	雅可比行列式与通用换元法	5
5	参考文献	9

1 定积分的换元法

在定积分中，可以使用换元法来简化定积分的求解¹：

$$\int_a^b f(x)dx = \int_{g^{-1}(a)}^{g^{-1}(b)} f(g(u)) g'(u)du \quad (1)$$

其中， $x = g(u)$ 和 $dx = g'(u)du$ 。

*本系列文档属于讲义性质，仅用于学习目的。Last updated on: July 17, 2020。

¹关于换元法的定理证明，详见文献 [1]。

上述换元公式也可以反过来使用，为统一表达，将前述公式中的 x 与 u 对调：

$$\int_a^b f(g(x)) g'(x) dx = \int_{g(a)}^{g(b)} f(u) du \quad (2)$$

其中， $u = g(x)$ 和 $du = g'(x)dx$ 。

例 1.1 计算 $\int_0^{\frac{\pi}{2}} \cos^5 x \sin x dx$ 。

解：

1. 显式地使用换元法

令 $u = \cos x$ ，则 $du = -\sin x dx$ ，且：

$$\begin{cases} x = 0 & \Rightarrow & u = 1 \\ x = \frac{\pi}{2} & \Rightarrow & u = 0 \end{cases} \quad (3)$$

则：

$$\int_0^{\frac{\pi}{2}} \cos^5 x \sin x dx = - \int_1^0 u^5 du = \int_0^1 u^5 du = \left[\frac{u^6}{6} \right]_0^1 = \frac{1}{6} \quad (4)$$

2. 不显式地使用换元法

$$\int_0^{\frac{\pi}{2}} \cos^5 x \sin x dx = - \int_0^{\frac{\pi}{2}} \cos^5 x d(\cos x) = - \left[\frac{\cos^6 x}{6} \right]_0^{\frac{\pi}{2}} = \frac{1}{6} \quad (5)$$

□

2 极坐标换元法

有些二重积分，使用极坐标 (Polar Coordinates) 替换直角坐标 (Rectangular Coordinates) 或笛卡尔坐标 (Cartesian Coordinates)，积分区域与被积函数均会变得简便些。实际上，这是一种特殊的换元法，被称为极坐标换元法。后文将推导出下面的结论：

$$\begin{cases} x = r \cos \theta \\ y = r \sin \theta \\ dA = r dr d\theta \end{cases} \quad (6)$$




图 2-1: 极坐标换元法示意图

其中, r 与 θ 是极坐标系中的分量, dA 表示极坐标系中的面积微元。于是, 得到:

$$\iint_R f(x, y) dx dy = \iint_S f(r \cos \theta, r \sin \theta) dA = \iint_S f(r \cos \theta, r \sin \theta) r dr d\theta \quad (7)$$

其中, R 是 $x-y$ 直角坐标系上的积分区域, S 是 $r-\theta$ 极坐标系上对应的积分区域。从上式可以看出, 直角坐标系中的面积微元为 $dx dy$, 而极坐标系中的面积微元为 $r dr d\theta$ 。

为了获得对两个坐标系下积分区域形状变化的直观认识, 我们来观察图2-1。可以看出, 极坐标系中的大矩形映射成直角坐标系中的 $\frac{1}{4}$ 圆弧; 极坐标系中的小矩形 (左子图的红色区域) 映射成直角坐标系中的截断扇形环 (右子图的红色区域)。此外, 左子图中标记为 (r_0, θ_0) 的点, 对应着右子图中标记为 (x_0, y_0) 的点, Δr 与 $\Delta \theta$ 在 2 个子图中均已标出。

下面来推导极坐标系中, dr 与 $d\theta$ 所形成的面积微元的计算公式。该过程可以借助于原有的直角坐标系——使用极坐标的划分方式, 即以极点为中心的一簇同心圆来划分积分区域, 参见图2-1的右子图。

为便于讨论, 将右子图中的局部单独展示出来, 如图2-2所示。红色区域的面积为:

$$\Delta A = \frac{1}{2} r_2^2 \Delta \theta - \frac{1}{2} r_1^2 \Delta \theta = \frac{r_2 + r_1}{2} (r_2 - r_1) \Delta \theta \quad (8)$$

其中, $\frac{r_2 + r_1}{2}$ 是 2 个半径的平均长度。

²需要注意的是, 在二重积分中, 对积分区域的划分是任意的。例如, 在直角坐标系中, 如果以平行于坐标轴的网格来划分积分区域, 则得到面积微元 $dx dy$, 而如果以极点为中心的一簇同心圆来划分积分区域 (参见图2-1的右子图), 则得到面积微元 $r dr d\theta$, 下文将表明这一点。




图 2-2: 截断扇形环

当 $r_2 - r_1 = \Delta r \rightarrow 0$ 时, $r_2 \approx r_1$, 则 $\frac{r_2+r_1}{2} \approx r_i (i=1,2)$ 。因而, 当 $\Delta r \rightarrow 0$ 和 $\Delta\theta \rightarrow 0$ 时:

$$\Delta A \approx r_i \Delta r \Delta \theta \Rightarrow dA = r dr d\theta \quad (9)$$

其中, $dA = r dr d\theta$ 就是极坐标系下的面积微元。于是, 得到:

$$\iint_R f(x, y) dx dy = \iint_S f(r \cos \theta, r \sin \theta) dA = \iint_S f(r \cos \theta, r \sin \theta) r dr d\theta \quad (10)$$

3 雅可比矩阵

雅可比矩阵 (Jacobian Matrix) 是函数的一阶偏导数以一定方式排列而成的矩阵。假设函数 $\mathbf{f}: \mathbb{R}^n \rightarrow \mathbb{R}^m$, 它将向量 $\mathbf{x} \in \mathbb{R}^n$ 映射到向量 $\mathbf{y} = \mathbf{f}(\mathbf{x}) \in \mathbb{R}^m$, 那么函数 \mathbf{f} 的雅可比矩阵被定义为 $m \times n$ 矩阵:

$$\mathbf{J} = \begin{bmatrix} \frac{\partial \mathbf{f}}{\partial x_1} & \cdots & \frac{\partial \mathbf{f}}{\partial x_n} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix} \quad (11)$$

当 $m = n$ 时, 雅可比矩阵的行列式被称为雅可比行列式 (Jacobian Determinant)³。

³在英文文献中, 一般将雅可比矩阵与雅可比行列式统称为 Jacobian。

我们知道，从变换的角度看，矩阵表示向量空间之间的某个变换。雅可比矩阵是由偏数组成的矩阵，而(偏)导数表示向量空间之间的线性变换。因此，雅可比矩阵表示的是，将向量空间 \mathbb{R}^n 中的点 (x_1, \dots, x_n) 线性变换为向量空间 \mathbb{R}^m 中的点 (y_1, \dots, y_m) ，即将一个 n 维欧式空间线性变换为另一个 m 维欧式空间。其意义在于，如果函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 在点 x 可微，那么点 x 的雅可比矩阵就是函数 f 在该点的最佳线性近似⁴。

另外，可以将雅可比矩阵理解为，单值实数函数的微分向多值或向量实数函数微分的泛化或扩展，即雅可比矩阵是多值或向量函数 f 在点 x 的微分或者偏导数。因此，也可以将雅可比矩阵记为 $\frac{\partial(f_1, \dots, f_m)}{\partial(x_1, \dots, x_n)}$ 、 $\frac{\partial(y_1, \dots, y_m)}{\partial(x_1, \dots, x_n)}$ 或 $J_f(x_1, \dots, x_n)$ 。

根据上述讨论，假设 x_0 是空间 \mathbb{R}^n 中的点，且 f 在 x_0 处可微，那么 $J_f(x_0)$ 就是函数 f 在点 x_0 处的(偏)导数(矩阵)。于是，当 x 充分靠近点 x_0 时，有：

$$f(x) \approx f(x_0) + J_f(x_0)(x - x_0) \quad (12)$$

或：

$$\Delta y \approx J_f(x_0) \Delta x \quad (13)$$

当 $m = 1$ 时，函数 f 退化为 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，它就是常规的标量函数⁵，雅可比矩阵退化为由偏数组成的行向量。特别地，当 $n = m = 1$ 时， $f: \mathbb{R} \rightarrow \mathbb{R}$ 是单变量标量函数，雅可比矩阵退化为一个导数标量。

4 雅可比行列式与通用换元法

前面，讨论了二重积分的极坐标换元法。下面，探讨适用于一般情形的通用换元法。

关于二重积分的通用换元法，首先给出如下结论⁶：


$$\iint_R f(x, y) dx dy = \iint_S f(x(u, v), y(u, v)) \left| \frac{\partial(x, y)}{\partial(u, v)} \right|_+ du dv \quad (14)$$

其中， $\left| \frac{\partial(x, y)}{\partial(u, v)} \right|_+$ 表示雅可比行列式的绝对值。该换元公式的应用，需要满足如下几个条件：

⁴实际上，可以将微分理解为线性化，将(偏)导数理解为线性变换。

⁵与之对应的是，前述的 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 被称为向量函数。

⁶具体的定理描述，请参考文献 [1]。

图 4-3: uOv 平面到 xOy 平面上的某个变换

- $x(u, v)$ 与 $y(u, v)$ 具有一阶连续偏导数;
- 雅可比行列式 $|\frac{\partial(x,y)}{\partial(u,v)}|$ 不等于 0;
- 在区域 R 与 S 上的变换是一对一的;

实际上, 上述积分换元公式可以扩展到 n 重积分情形。

下面推导二重积分的通用换元公式。注意, 下面的推导, 均在直角坐标系的视角下进行⁷。图4-3展示了变换:

$$\begin{cases} x = x(u, v) \\ y = y(u, v) \end{cases} \quad (16)$$

它将直角坐标平面 uOv 上的点 (u, v) , 通过上式, 变换为直角坐标平面 xOy 上的点 (x, y) 。

在图4-3中, 标出了几个关键点及其坐标分量的对应关系, 其中 $(x_0, y_0) = (x(u_0, v_0), y(u_0, v_0))$ 。为了便于理解直角坐标平面 uOv 下面积微元的求解过程, 将图4-3的右子图单独放大显示, 如图4-4所示。

根据变换公式 (16) 及“一对一”的约束条件, uOv 平面上的每一点 (u, v) , 在 xOy 平面上, 必然存在唯一的点 (x, y) 与之对应, 反之亦然。为了表达方便, 将

⁷即便是前述的极坐标换元法, 仍然可以认为是直角坐标系下执行的某种变换——把公式:

$$\begin{cases} x = r \cos \theta \\ y = r \sin \theta \end{cases} \quad (15)$$

看成是从直角坐标平面 $rO\theta$ 到直角坐标平面 xOy 的某种变换。




图 4-4: 面积微元示意图

(x, y) 表达成向量形式, 于是, 可令:

$$(x, y) = x\hat{i} + y\hat{j} = x(u, v)\hat{i} + y(u, v)\hat{j} = \vec{r}(u, v) \quad (17)$$

即 $\vec{r}(u, v)$ 表示 uOv 平面上的点 (u, v) 在 xOy 平面上形成的像 (Image) 点或位置向量 (Position Vector)。

于是, 在图4-4中, 点 $(x(u_0, v_0), y(u_0, v_0))$ 对应 $\vec{r}(u_0, v_0)$, 点 $(x(u, v_0), y(u, v_0))$ 对应 $\vec{r}(u, v_0)$, 点 $(x(u_0, v), y(u_0, v))$ 对应 $\vec{r}(u_0, v)$ 。

当 $\Delta u \rightarrow 0$ 和 $\Delta v \rightarrow 0$ 时, 图4-4中面积微元 (橙色) R 的面积, 可近似为图4-4中平行四边形 (蓝色) 的面积, 即⁸:

$$\Delta A \approx \|(\vec{r}(u, v_0) - \vec{r}(u_0, v_0)) \times (\vec{r}(u_0, v) - \vec{r}(u_0, v_0))\| \quad (18)$$

设 $\vec{r}(u_0, v_0)$ 处 u 方向的切向量 (Tangent Vector) 为 $\vec{r}_u(u_0, v_0)$, 则该切向量就是 $\vec{r}(u, v)$ 关于 u 的偏导数在 (u_0, v_0) 处的值, 即:

$$\vec{r}_u(u_0, v_0) = \left. \frac{\partial x(u, v)}{\partial u} \hat{i} + \frac{\partial y(u, v)}{\partial u} \hat{j} \right|_{u=u_0, v=v_0} \quad (19)$$

类似地, 设 $\vec{r}(u_0, v_0)$ 处 v 方向的切向量为 $\vec{r}_v(u_0, v_0)$, 则该切向量就是 $\vec{r}(u, v)$ 关于 v 的偏导数在 (u_0, v_0) 处的值, 即:

$$\vec{r}_v(u_0, v_0) = \left. \frac{\partial x(u, v)}{\partial v} \hat{i} + \frac{\partial y(u, v)}{\partial v} \hat{j} \right|_{u=u_0, v=v_0} \quad (20)$$

⁸公式的推导, 请阅读《机器学习》课程系列之《叉积》一章。

而根据偏导数的定义有：

$$\vec{r}_u(u_0, v_0) = \lim_{\Delta u \rightarrow 0} \frac{\vec{r}(u_0 + \Delta u, v_0) - \vec{r}(u_0, v_0)}{\Delta u} = \lim_{\Delta u \rightarrow 0} \frac{\vec{r}(u, v_0) - \vec{r}(u_0, v_0)}{\Delta u} \quad (21)$$

因而，当 $\Delta u \rightarrow 0$ 时，有：

$$\vec{r}(u, v_0) - \vec{r}(u_0, v_0) \approx \Delta u \vec{r}_u(u_0, v_0) \quad (22)$$

同理，当 $\Delta v \rightarrow 0$ 时，可得：

$$\vec{r}(u_0, v) - \vec{r}(u_0, v_0) \approx \Delta v \vec{r}_v(u_0, v_0) \quad (23)$$

从而，从公式 (18) 出发，进一步得到：

$$\begin{aligned} \Delta A &\approx \|(\vec{r}(u, v_0) - \vec{r}(u_0, v_0)) \times (\vec{r}(u_0, v) - \vec{r}(u_0, v_0))\| \\ &\approx \|\Delta u \vec{r}_u(u_0, v_0) \times \Delta v \vec{r}_v(u_0, v_0)\| \\ &= \Delta u \Delta v \|\vec{r}_u(u_0, v_0) \times \vec{r}_v(u_0, v_0)\| \end{aligned} \quad (24)$$

上式中，鉴于 (u_0, v_0) 的任意性，为表达简便，将其从公式中去掉，并将叉积写成行列式的形式：

$$\begin{aligned} \vec{r}_u \times \vec{r}_v &= \begin{vmatrix} \hat{i} & \hat{j} & \hat{k} \\ \frac{\partial x(u,v)}{\partial u} & \frac{\partial y(u,v)}{\partial u} & 0 \\ \frac{\partial x(u,v)}{\partial v} & \frac{\partial y(u,v)}{\partial v} & 0 \end{vmatrix} \\ &= \begin{vmatrix} \frac{\partial x(u,v)}{\partial u} & \frac{\partial y(u,v)}{\partial u} \\ \frac{\partial x(u,v)}{\partial v} & \frac{\partial y(u,v)}{\partial v} \end{vmatrix} \hat{k} \end{aligned} \quad (25)$$

得到：

$$\|\vec{r}_u \times \vec{r}_v\| = \begin{vmatrix} \frac{\partial x(u,v)}{\partial u} & \frac{\partial y(u,v)}{\partial u} \\ \frac{\partial x(u,v)}{\partial v} & \frac{\partial y(u,v)}{\partial v} \end{vmatrix}_+ = \left| \frac{\partial(x, y)}{\partial(u, v)} \right|_+ \quad (26)$$

上式就是雅可比行列式的绝对值。

因此，当 $\Delta u \rightarrow 0$ 和 $\Delta v \rightarrow 0$ 时，从公式 (24) 出发，得到：

$$\Delta A \approx \Delta u \Delta v \|\vec{r}_u \times \vec{r}_v\| \Rightarrow dA = \left| \frac{\partial(x, y)}{\partial(u, v)} \right|_+ du dv \quad (27)$$

从而，得到：

$$\begin{aligned} \iint_R f(x, y) dx dy &= \iint_S f(x(u, v), y(u, v)) dA \\ &= \iint_S f(x(u, v), y(u, v)) \left| \frac{\partial(x, y)}{\partial(u, v)} \right|_+ du dv \end{aligned} \quad (28)$$

实际上，前述的极坐标换元法是通用换元法的特例：

$$\left| \frac{\partial(x, y)}{\partial(r, \theta)} \right|_+ = \left| \begin{array}{cc} \frac{\partial x}{\partial r} & \frac{\partial y}{\partial r} \\ \frac{\partial x}{\partial \theta} & \frac{\partial y}{\partial \theta} \end{array} \right|_+ = \left| \begin{array}{cc} \cos \theta & \sin \theta \\ -r \sin \theta & r \cos \theta \end{array} \right|_+ = r \quad (29)$$

于是，面积微元为：

$$dA = r dr d\theta \quad (30)$$

5 参考文献

1. 同济大学数学教研室。《高等数学》，1978 年 10 月第 1 版。
2. Jacobian matrix and determinant. https://en.wikipedia.org/wiki/Jacobian_matrix_and_determinant.
3. 雅可比矩阵. <https://zh.wikipedia.org/wiki/雅可比矩阵>.
4. Substitution. <https://math.libretexts.org/>.
5. Double Integration with Polar Coordinates. <https://math.libretexts.org/>.
6. Change of Variables in Multiple Integrals (Jacobians). <https://math.libretexts.org/>.